

Lecture 6 Theory of Generalization

整理者: LobbyBoy* 2020年2月19日

1. Restriction of Break Point

在上一章的后半段, 我们针对二元分类问题下的假说集合, 定义了假说集合的“增长函数”, 记作 $m_{\mathcal{H}}(N)$, 表示该假说集合最多能够将 N 个样本点划分出多少种dichotomies, 即“对分”。对于2D感知机, 我们目前已知的信息是: $m_{\mathcal{H}}(N) < 2^N$, 因为从 $N=4$ 开始, 无论如何它都不能将输入集合shatter掉, 例如 $N=4$ 时, 增长函数的值便为14, 而不是16。我们把 $N=4$ 称为2D感知机的一个“断点(break point)”, 也是最小的断点。下面我们要研究的是在(最小)断点之后增长函数的增长情况。有一点我们是明确的, 那就是在(最小)断点之后, 增长函数并不再以指数型的方式增长, 其增长的速度会下降。

为了使结论更具一般性, 我们仅假设存在一个假说集合, 其(最小)断点为2, 除此之外没有其他信息。我们将根据 $k=2$ 这条信息进行一系列推导。

首先, 根据断点的定义, 我们知道 $m_{\mathcal{H}}(1) = 2$, $m_{\mathcal{H}}(2) < 4$ 。因此, $m_{\mathcal{H}}(2)$ 最大可能值为3, 也就是说该假说集合无法shatter掉任何两个样本点。当 $N=3$ 时, 情况如何? 我们可以采用如下方法进行演绎: 每写一种dichotomy, 然后回头检查已存在的dichotomies有没有违反“假说集合不能打散任何2个样本点”的前提条件: 如果没有, 则纳入该dichotomy; 如果违反, 则放弃该dichotomy。最后看看最多可以写出多少种dichotomies, 将其作为 $N=3$ 时增长函数的上界。

maximum possible $m_{\mathcal{H}}(N)$ when $N = 3$ and $k = 2$?			
maximum possible so far: 4 dichotomies			
x_1	x_2	x_3	
○	○	○	
○	○	×	
○	×	○	
×	○	○	
⊖	⊖	⊖	

图 1: $N=3, k=2$

*本笔记根据台湾大学林轩田教授于线上教育平台Coursera开设的“机器学习基石”课程整理而成(课程内容见: <https://www.coursera.org/learn/ntumlone-mathematicalfoundations/home/welcome>)。笔记内的大多数图片来自于林老师的课程slides。感谢林老师能够将如此精彩的课程通过线上平台同所有人分享, thanks!

通过尝试我们发现，在 $N=3$ 时，增长函数的上界为4，比 $2^3 = 8$ 小了很多。当 $N=2$ 时，增长函数的上界为3，只比 $2^2 = 4$ 小1。可见发现，在(最小)断点之后，增长函数的上界被“限制”住了，且限制的力度仿佛随着 N 的增大而越来越显著。

最后，我们将研究方向转向增长函数的上界。理由很简单，因为研究增长函数本身，需要结合具体的某一个假说集合，不同的假说集合一般具有不同的增长函数；但研究增长函数的上界，我们可以仅仅从“断点”与“对分组合”切入，而不用关心假说集合的具体形式。例如，我们刚刚对于(最小)断点是2的假说集合的一番演绎，完全没有考虑假说集合的具体形式，但仍然推出了很多关于该假说集合的增长函数上界的信息。也就是说，增长函数上界可能仅与断点有关，而与具体的假说集合形式无关。

2. Bounding Function: Basic Cases

本节我们首先定义Bounding Function: bounding function，记作 $B(N, k)$ ，表示当(最小)断点为 k 时增长函数 $m_{\mathcal{H}}(N)$ 的最大可能值(上界)。研究bounding function可以帮助我们忽略假说集合和增长函数的具体形式，转而仅需关注组合数的问题(combinatorial quantity)。具体而言， $B(N, k)$ 的含义是，已知(最小)断点为 k (N 个样本中任何 k 长度的子样本都不能被打散，但 $k-1$ 可以)，则 N 个样本最多可能产生多少种对分方式。

$B(N, k)$		k						
		1	2	3	4	5	6	...
N	1	1	2	2	2	2	2	...
	2	1	3	4	4	4	4	...
	3	1	4	7	8	8	8	...
	4	1			15	16	16	...
	5	1				31	32	...
	6	1					63	...
	\vdots	\vdots						\ddots

图 2: Table of Bounding Function

首先，第一列全部是1，因为当 $k=1$ 时，表示连1个点都不能打散，那么最大的可能对分数就均为1。其次，对角线部分也很容易填，因为当 $N = k$ 时，表示不能够打散任何 N 个点，那么最多可能的对分就为 $2^N - 1$ 种。最后，右上角的部分，即 $N < k$ ，根据(最小)断点的定义，这些地方的 N 都能够以某种存在形式被打散，因此等于 2^N 。此外， $B(3, 2)$ 在此前计算过，为4。

3. Bounding Function: Inductive Cases

本节我们将以计算 $B(4, 3)$ 为例，推导如何计算表格左下方的空缺。一个直观的猜想是， $B(4, 3)$ 可能与 $B(3, ?)$ 有关，因为 $N = 4$ 是在 $N = 3$ 的基础上增加了一个样本点而得到的。因此，我们首先用电脑程序帮助我们找到 $B(4, 3)$ 的解：当 $N = 4$ 时，最多最多有 $2^4 = 16$ 种对

分，因此也就有 2^{16} 个“对分集(dichotomy set)”；我们用程式遍历这 2^{16} 个对分集，看看哪个对分集在满足任何3个样本点没有被打散的条件下，数量最多，它就是 $B(4,3)$ 的解。结果如下， $B(4,3) = 11$ ：

	x_1	x_2	x_3	x_4
01	o	o	o	o
02	x	o	o	o
03	o	x	o	o
04	o	o	x	o
05	o	o	o	x
06	x	x	o	x
07	x	o	x	o
08	x	o	o	x
09	o	x	x	o
10	o	x	o	x
11	o	o	x	x

\Rightarrow

	x_1	x_2	x_3	x_4
01	o	o	o	o
05	o	o	o	x
02	x	o	o	o
08	x	o	o	x
03	o	x	o	o
10	o	x	o	x
04	o	o	x	o
11	o	o	x	x
06	x	x	o	x
07	x	o	x	o
09	o	x	x	o

orange: pair; purple: single

图 3: Reorganized Dichotomies of $B(4,3)$

看到 $B(4,3) = 11$ ，我们猜想， $B(4,3) = 11 = 7 + 4 = B(3,3) + B(3,2)$ 。观察 $B(4,3)$ 的解，我们大致可以将这11个对分分成两组：orange组容纳了所有在 x_1, x_2, x_3 上成双成对的对分，而purple组则是形单影只的对分。我们将orange组数量的一半记为 α ，purple组的数量记为 β ，则 $B(4,3) = 2\alpha + \beta$ 。

	x_1	x_2	x_3
α	o	o	o
	x	o	o
	o	x	o
	o	o	x
β	x	x	o
	x	o	x
	o	x	x

图 4: $\alpha + \beta$

首先我们来看 $\alpha + \beta$ 。 $\alpha + \beta$ 是关于3个点： x_1, x_2, x_3 的对分的数量，而此时 $k=3$ ，因此一定有：

$$\alpha + \beta \leq B(3,3)$$

	x_1	x_2	x_3
α	o	o	o
	x	o	o
	o	x	o
	o	o	x

图 5: α

接着我们单看 α 。 α 也是关于3个点： x_1, x_2, x_3 的对分的数量。但对于 α 中的每一个对

分，都有另一个 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 与之一摸一样但 \mathbf{x}_4 完全相反的对分。因此， α 中任何2个点都不能被打散，因为如果存在2个点被打散，那么配合上 \mathbf{x}_4 ，则存在3个点被打散的情况，这与 $k=3$ 矛盾。因此，我们会有：

$$\alpha \leq B(3, 2)$$

综合上述两个推论，我们可以得到：

$$B(4, 3) = 2\alpha + \beta \leq B(3, 3) + B(3, 2)$$

也就是说，我们得到了bounding function的上界，可以根据某个空缺的正上方及其左上方的数据填出该空缺的上界(注意，这里还不是确切值，只是上界)：

Putting It All Together							
$B(N, k) = 2\alpha + \beta$ $\alpha + \beta \leq B(N-1, k)$ $\alpha \leq B(N-1, k-1)$ $\Rightarrow B(N, k) \leq B(N-1, k) + B(N-1, k-1)$							
$B(N, k)$	1	2	3	4	5	6	
1	1	2	2	2	2	2	
2	1	3	4	4	4	4	
3	1	4	7	8	8	8	
4	1	≤ 5	11	15	16	16	
5	1	≤ 6	≤ 16	≤ 26	31	32	
6	1	≤ 7	≤ 22	≤ 42	≤ 57	63	

now have **upper bound** of bounding function

图 6: Putting It All Together

下面我们将利用数学归纳法及递推式：

$$B(N, k) \leq B(N-1, k) + B(N-1, k-1)$$

证明Sauer's Lemma:

$$B(N, k) \leq \sum_{i=0}^{k-1} \binom{N}{i}$$

证明如下(补充一小点，组合数 $\binom{n}{r}$ 中当 $n < r$ 时也是有意义的，唯一要求是 r 必须为非负整数， n 为整数即可。有 $\binom{n}{r} = \frac{n(n-1)(n-2)\dots(n-r+1)}{r!}$)：首先，我们将验证 $N=1$ (任意 k)时，上式成立。当 $N=1$ 时，先考虑 $k=1$ ：

$$RHS = \sum_{i=0}^0 \binom{1}{i} = \binom{1}{0} = 1 \geq 1 = B(1, 1) = LHS$$

再考虑 $k \geq 2 (N=1)$:

$$RHS = \sum_{i=0}^{k-1} \binom{1}{i} = \binom{1}{0} + \binom{1}{1} = 2 \geq 2 = B(1, k) = LHS$$

综上，当 $N=1$ (任意 k) 时，待证不等式均成立。下面假设对于 $N \leq N_0$ (任意 k)，待证不等式均成立；我们需要推导，对于 $N = N_0 + 1$ (任意 k)，待证不等式均成立。如下图：

		k						
		1	2	3	4	5	6	...
N	1	1	2	2	2	2	2	...
	2	1	3	4	4	4	4	...
	3	1	4	7	8	8	8	...
	4	1	5	11
	5	1	6
	6	1	7

图 7: 证明逻辑

由递推式可知：

$$B(N_0 + 1, k) \leq B(N_0, k) + B(N_0, k - 1)$$

基于假设，我们可以将待证不等式带入上述递推不等式的右侧，得：

$$\begin{aligned}
 LHS = B(N_0 + 1, k) &\leq \sum_{i=0}^{k-1} \binom{N_0}{i} + \sum_{i=0}^{k-2} \binom{N_0}{i} \\
 &= \binom{N_0}{0} + \sum_{i=1}^{k-1} \binom{N_0}{i} + \sum_{i=1}^{k-1} \binom{N_0}{i-1} \\
 &= 1 + \sum_{i=1}^{k-1} \left[\binom{N_0}{i} + \binom{N_0}{i-1} \right] \\
 &= 1 + \sum_{i=1}^{k-1} \left[\binom{N_0 + 1}{i} \right] \\
 &= \sum_{i=0}^{k-1} \binom{N_0 + 1}{i} = RHS
 \end{aligned}$$

综上，基于数学归纳法，我们证明了 Sauer's Lemma，即：

$$B(N, k) \leq \sum_{i=0}^{k-1} \binom{N}{i}$$

注意到, Sauer's Lemma中不等式右侧是组合数连加, 且是关于N的k-1次多项式(来自 $\binom{N}{k-1}$)。因此, $B(N, k) \leq \text{poly}(N)$ ——当然, 条件是断点k存在。

综上, 对于具有(最小)断点k的某个假说集合 \mathcal{H} , 有 $m_{\mathcal{H}}(N) \leq B(N, k) \leq \text{poly}(N)$, 即其增长函数被一个关于N的多项式限制住了, 而非指数式。也就是说, 如果某个假说集合存在(最小)断点k, 那么其增长函数就可以被某个关于N的k-1次多项式bound住。

4. A Pictorial Proof

回忆multiple bins版本的Hoeffding不等式:

$$P\left[|E_{in}(g) - E_{out}(g)| > \epsilon\right] \leq 2 \cdot M \cdot \exp(-2\epsilon^2 N)$$

其中 g 表示由某个演算法A从假说集合 \mathcal{H} 中挑选并回传的hypothesis。正是由于此处的 g 不是固定的hypothesis, 而是一个会随着演算法改变而变化的回传结果(可以看成是随机的), 因此不可以直接对它使用Hoeffding不等式。

Multiple bins版本的Hoeffding不等式有另一种写法, 这也是课件第4节第一张幻灯片中的写法:

$$P\left[\exists h \in \mathcal{H} \text{ s.t. } |E_{in}(h) - E_{out}(h)| > \epsilon\right] \leq 2 \cdot M \cdot \exp(-2\epsilon^2 N)$$

记第一个不等式左侧P中的事件为B, 记上式左侧P中的事件为C, 易知 $B \subset C$, 即“回传结果 g 是bad”一定能够推出“在假说集合中有某个 h 是bad”, 因为回传结果当然是从假说集合中挑选出来的。然后对 $P(C)$ 使用union bound便得到了multiple bins版本的Hoeffding不等式的右侧。

我们本章到现在所做的工作, 就是想要将上式右侧中的M换成某个其他的对假说集合大小度量的指标。现在我们有了增长函数 $m_{\mathcal{H}}(N)$ 。那么是否能够直接将M换成 $m_{\mathcal{H}}(N)$ 呢? 可以, 但是替换后还需进行一些系数的调整, 最终的结果为:

$$P\left[\exists h \in \mathcal{H} \text{ s.t. } |E_{in}(h) - E_{out}(h)| > \epsilon\right] \leq 4 \cdot m_{\mathcal{H}}(2N) \cdot \exp\left(-\frac{1}{8}\epsilon^2 N\right)$$

上式被称为Vapnik-Chervonenkis bound, 简称VC bound。利用上式对2D perceptron进行分析: 2D perceptron的最小断点为 $k=4$, 因此其增长函数是一个最高次数为 $4-1=3$ 的多项式; 因此在N非常大的时候, VC bound右侧的界会趋于零; 这样就保证了任何一个演算法选出的hypothesis, 其in-sample error会是out-of-sample error的较好反映。